

Master II Livello in Intelligenza Artificiale

Corso di Generative AI

Document Understanding con Vision LLM: Costruzione di Dataset Corrotto, Benchmarking e Strategie di Mitigazione

Antonio Roberto Buonfiglio

Giugno 2026

Indice

1	Introduzione e Obiettivi	3
2	Metodologia	3
2.1	Dataset: DocVQA	3
2.2	Corruzione (Parte 1)	3
2.3	Modelli di benchmark (Parte 2)	3
2.4	Prompt di inferenza	4
2.5	Metriche di valutazione	4
2.6	Strategie di mitigazione (Parte 3)	4
3	Risultati	5
3.1	Benchmarking pre-mitigazione (Parte 2)	5
3.1.1	Metriche aggregate	5
3.1.2	Matrici di confusione	5
3.1.3	Recall per tipo di corruzione	6
3.2	Risultati della mitigazione (Parte 3)	6
3.2.1	Recall per classe attraverso le strategie	6
3.2.2	Evoluzione delle metriche aggregate	6
3.2.3	Analisi per tipo di corruzione	7
3.2.4	Impatto differenziale delle strategie	7
4	Discussione e Conclusioni	7
4.1	Principali osservazioni	7
4.2	Conclusione	8

1 Introduzione e Obiettivi

Il presente documento descrive il lavoro svolto nell’ambito dell’esercitazione “*Document Understanding*” del corso di Generative AI. L’obiettivo generale è valutare la capacità dei modelli *Vision Large Language Model* (Vision LLM) di distinguere domande *rispondibili* (ANSWERABLE) da domande *non rispondibili* (UNANSWERABLE) su documenti visuali, in un contesto in cui le domande sono state deliberatamente corrotte per renderle prive di risposta. L’analisi completa si può trovare al seguente link della repository GitHub: <https://github.com/buonfiglio/GenAI.git>.

2 Metodologia

2.1 Dataset: DocVQA

Come dataset sono stati utilizzati 1000 elementi estratti dal validation set di *lmms-lab/DocVQA*, composto da coppie domanda-risposta associate a immagini di documenti reali. Ogni campione è identificato da un `questionId` e da un `doc_id`.

2.2 Corruzione (Parte 1)

Vengono definiti sei tipi di corruzione, raggruppati in tre categorie. La qualità delle domande corrotte viene verificata tramite un modello `Qwen2.5-VL-7B-Instruct` che opera come giudice.

Tabella 1. Tipi di corruzione delle domande implementati in `pypart1.py`

Tipo	Descrizione
<code>nlp_entity</code>	Sostituzione di entità numeriche o named entity nella domanda
<code>element</code>	Sostituzione di elementi visivi (es. riferimento a forme, colori)
<code>layout</code>	Sostituzione di termini spaziali (es. <i>top</i> → <i>bottom</i>)
<code>nlp_entity+element</code>	Corruzione combinata di entità NLP ed elementi visivi
<code>nlp_entity+layout</code>	Corruzione combinata di entità NLP e layout spaziale
<code>element+layout</code>	Corruzione combinata di elementi visivi e layout

2.3 Modelli di benchmark (Parte 2)

I cinque modelli selezionati per il benchmarking sono:

Tabella 2. Panel di modelli Vision LLM valutati in `pypart2.py`

Identificatore HuggingFace	Famiglia	Dim. appross.
<code>google/gemma-3-4b-it</code>	Gemma-3	~4B
<code>google/gemma-3-12b-it</code>	Gemma-3	~12B
<code>HuggingFaceTB/SmolVLM-Instruct</code>	SmolVLM	~2B
<code>Qwen/Qwen2.5-VL-3B-Instruct</code>	Qwen2.5-VL	~3B
<code>google/gemma-4-E2B-it</code>	Gemma-4	~2B

2.4 Prompt di inferenza

Il prompt utilizzato per la classificazione binaria è il seguente:

"You are evaluating a document question-answering system. Look at the document image carefully. Can the following question be answered SOLELY from the content visible in this document?

Question: question

Reply with ONE word only: ANSWERABLE or UNANSWERABLE"

2.5 Metriche di valutazione

Le metriche principali sono:

- **Accuracy:** $Acc = \frac{TP+TN}{TP+TN+FP+FN}$
- **Macro F1:** media aritmetica degli F1 delle due classi
- **Unanswerable Recall:** $R_U = \frac{TP_U}{TP_U+FN_U}$, metrica primaria dell'esercitazione
- **Unanswerable F1:** $F1_U = \frac{2 \cdot P_U \cdot R_U}{P_U + R_U}$

2.6 Strategie di mitigazione (Parte 3)

Le cinque strategie di in-context learning implementate in `pypart3.py` sono:

1. **few-shot:** esempi generici di coppie ANSWERABLE/UNANSWERABLE
2. **expl. few-shot:** esempi arricchiti di spiegazione esplicita
3. **layout few-shot:** esempi mirati alle corruzioni spaziali
4. **multi few-shot:** combinazione di esempi da tipi multipli
5. **skeptical:** prompt zero-shot che allerta il modello dell'esistenza di corruzioni intenzionali

3 Risultati

3.1 Benchmarking pre-mitigazione (Parte 2)

3.1.1 Metriche aggregate




Figura 1. Metriche aggregate del benchmark per tutti e cinque i modelli (accuracy, macro F1, unanswerable F1, unanswerable recall). **gemma-4-E2B-it** raggiunge il bilanciamento ottimale con tutte le metriche a ~ 0.75 . **Qwen2.5-VL-3B-Instruct** mostra unanswerable recall ≈ 0.97 ma accuracy depressa (0.69) a causa del forte bias verso la classe UNANSWERABLE. **SmolVLM-Instruct** collassa con accuracy 0.50 e unanswerable recall ≈ 0.02 .

Tabella 3. Metriche di benchmark per i quattro modelli con grafici disponibili

Modello	Accuracy	Macro F1	Unansw. F1	Unansw. Recall
gemma-3-4b-it	0.73	0.72	0.65	0.51
gemma-3-12b-it	0.77	0.76	0.71	0.58
SmolVLM-Instruct	0.50	0.35	0.03	0.02
gemma-4-E2B-it	0.75	0.75	0.75	0.75

3.1.2 Matrici di confusione




Figura 2. Matrici di confusione per tutti e cinque i modelli. **Qwen2.5-VL-3B-Instruct:** $TP_U=912$, $FN_U=25$, recall unanswerable $912/(912+25) \approx 0.97$, ma $FP=568$ e $TN=369$, confermando il bias verso UNANSWERABLE. **gemma-4-E2B-it:** $TP_U=704$, $FN_U=233$, $FP=226$, $TN=711$, recall ≈ 0.75 . **SmolVLM-Instruct** classifica 917 su 937 campioni UNANSWERABLE come ANSWERABLE.

3.1.3 Recall per tipo di corruzione




Figura 3. Heatmap della unanswerable recall per tutti e cinque i modelli e per tipo di corruzione. **Qwen2.5-VL-3B-Instruct** mostra recall ≥ 0.94 su tutti i tipi (massimo 1.00 su `element+layout` e `nlp_entity+layout`). Il tipo `layout` rimane il più difficile per i modelli Gemma-3 (recall 0.11–0.14). **gemma-4-E2B-it** mostra il profilo più bilanciato tra i modelli non biasati (recall 0.40–0.93).

3.2 Risultati della mitigazione (Parte 3)

3.2.1 Recall per classe attraverso le strategie




Figura 4. Recall per classe (blu = ANSWERABLE, arancione = UNANSWERABLE) al variare della strategia di mitigazione per tutti e cinque i modelli. La strategia **skeptical** produce i guadagni maggiori per i modelli con bias ANSWERABLE (gemma-3-4b-it: +0.212; gemma-3-12b-it: +0.116). **Qwen2.5-VL-3B-Instruct** presenta il pattern inverso: recall unanswerable elevata in baseline, crollo drastico con la *skeptical*.

3.2.2 Evoluzione delle metriche aggregate




Figura 5. Evoluzione di Macro F1, Unanswerable F1 e Unanswerable Recall al variare delle strategie di mitigazione. **gemma-4-E2B-it** mostra la curva più stabile (Macro F1 tra 0.67 e 0.74). **Qwen2.5-VL-3B-Instruct** è il modello più instabile: la condizione *skeptical* causa un collasso della Macro F1 a ~ 0.45 .

3.2.3 Analisi per tipo di corruzione




Figura 6. Heatmap della unanswerable recall per tipo di corruzione e strategia di mitigazione, per tutti e cinque i modelli. La colonna `layout` rimane la più critica per i Gemma-3 (baseline 0.11–0.14, massimo 0.47 con *skeptical*). Le corruzioni `nlp_entity` e `nlp_entity+layout` sono le più riconoscibili. **Qwen** mostra recall ≥ 0.94 in quasi tutte le celle in baseline.

3.2.4 Impatto differenziale delle strategie




Figura 7. Variazione Δ della unanswerable recall rispetto alla baseline per ciascuna strategia e modello. La strategia *skeptical* è la più efficace per i modelli con bias ANSWERABLE: +0.212 (gemma-3-4b-it), +0.116 (gemma-3-12b-it), +0.082 (SmolVLM). Le strategie few-shot causano un crollo catastrofico per **Qwen2.5-VL-3B-Instruct** ($\Delta = -0.973$).

4 Discussione e Conclusioni

4.1 Principali osservazioni

Due bias opposti. I risultati rivelano che il problema del bias non è unidirezionale. **SmolVLM-Instruct** e i modelli Gemma-3 mostrano il bias atteso verso ANSWERABLE: tendono a rispondere come se ogni domanda trovasse risposta nel documento. Al contrario, **Qwen2.5-VL-3B-Instruct** presenta un bias opposto quasi assoluto, con unanswerable recall ≈ 1 ma answerable recall quasi nulla, portando a Macro F1 depressa (~ 0.65).

La strategia *skeptical* è la più efficace per i modelli biasati verso answerable. Il prompt zero-shot che ricontestualizza esplicitamente il task produce i guadagni più consistenti:

+0.212 per gemma-3-4b-it, +0.116 per gemma-3-12b-it, +0.082 per SmolVLM. Questa strategia risulta però controproducente per Qwen2.5-VL-3B-Instruct ($\Delta = -0.022$), il cui bias preesistente viene amplificato.

Le strategie few-shot producono effetti indesiderati. Le varianti few-shot generano delta negativi per i modelli Gemma-3 e un collasso catastrofico per Qwen ($\Delta = -0.973$), che interpreta gli esempi come indicazione per invertire il proprio comportamento.

La corruzione layout rimane la sfida più aperta. Le corruzioni spaziali sono le più difficili da rilevare per tutti i modelli ad eccezione di Qwen. Nei modelli Gemma-3, la recall su `layout` in baseline non supera 0.10–0.14, salendo a 0.29–0.47 con *skeptical*.

gemma-4-E2B-it emerge come il modello più robusto. Pur non avendo le recall più alte, gemma-4-E2B-it presenta il profilo più stabile: delta moderati e mai catastrofici, Macro F1 compresa tra 0.67 e 0.74, bilanciamento ragionevole tra le due classi.

4.2 Conclusioni

La principale conclusione empirica è che il prompting di tipo *skeptical* è più efficace degli esempi few-shot per migliorare la unanswerable recall, con guadagni fino a +0.212 su gemma-3-4b-it, ma la sua efficacia dipende criticamente dalla direzione del bias preesistente del modello. La corruzione di tipo `layout` costituisce un limite strutturale non superabile tramite prompting, suggerendo che la comprensione spaziale dei documenti rimane una sfida aperta per i Vision LLM di taglia media.